FraudInsight XAI

DÉTECTION DE FRAUDE EXPLICABLE | ENSI | 2026-2027

Data Mining - II3-IA / II3-IF - Challenge 2 - Mme Rym Besrour

Décision étudiée. Prioriser les transactions à examiner avec une capacité hypothétique de 50 alertes/jour. Les résultats ci-dessous proviennent de l'exécution réelle (complet).

Données. Sparkov / Kartik Shenoy, Kaggle version 1, CC0 Public Domain. 1,852,394 transactions synthétiques, 9,651 fraudes (0.521%). Période : 2019-01-01 au 2020-12-31. Devise : USD.

Protocole. Séparation chronologique 60/20/20, sans ex aequo entre périodes. Fenêtres strictement antérieures sur 1 h, 24 h et 30 j ; encodeurs, médianes et échelles appris sur train. Pondération comparée au témoin non pondéré. Logistique, boosting, Isolation Forest et LOF novelty ; anomalies ajustées sans labels.

Détecteur	AP test	ROC-AUC	F2	MCC	Coût test USD
logistic	0.1648	0.9492	0.4232	0.3468	138,434
boosting	0.8601	0.9977	0.7768	0.6599	24,535
isolation	0.0408	0.8582	0.1084	0.0899	593,575
lof	0.0386	0.8513	0.1176	0.0916	588,007

Choix validation : boosting. Seuil figé : 0.882626. Coût validation : 31,405.93 USD ; coût test indépendant : 24,534.66 USD ; sans alerte : 733,911.72 USD. Test : 2,643 alertes, pic 47/jour.

Budget @k. Précision@k : 20.202% ; rappel@k : 96.590% ; k total : 6,450 dossiers, jusqu'à 50/jour (classement rétrospectif). AP = Average Precision.

Hypothèses financières. Coût = montants frauduleux × (1 - efficacité × alerte) + coût unitaire × alertes. Analyse : 5.00 USD/alerte ; prévention/récupération : 100%. Le seuil minimise ce coût en validation sous plafond quotidien ; aucun réglage sur le test.

Explication et service. SHAP global et local sur les modèles supervisés, contributions en log-odds, additivité vérifiée ; catégorie one-hot agrégée. Interface française à six modules, FastAPI réellement appelée par HTTP interne. Modèles figés et extrait sans identités pour la démonstration.

Limites. Données simulées ; probabilités non calibrées ; budgets bornés pour les anomalies ; capacité future non garantie par un seuil fixe ; efficacité hypothétique ; pas de coûts de friction ni intervalles de confiance. SHAP décrit des associations, sans preuve causale. Déploiement public non réalisé.

Source : kaggle.com/datasets/kartik2112/fraud-detection | Résultats détaillés : reports/results.json | Rapport une page supplémentaire demandé par le commanditaire.